Université Mohammed V de Rabat
Faculté des Sciences - Rabat

Filière : Master Intelligent Processing Systems

Construction d'un entrepôt de données à partir de sources CSV : Application du PMB

Réalisé par :

Wijdan **ELBAKHOUCHI**
Maryam **CHOUKI**
Boutayna **DAKKI**

Encadré par :
Pr. Mohamed **AMMARI**

Année universitaire : 2024 - 2025

Contents

1 Introduction **2**
1.1 Contexte . . . 2
1.2 Objectifs . . . 2

2 Nettoyage et Préparation des Données **3**
2.1 Analyse des fichiers CSV et XLS . . . 3
2.1.1 Identification et compréhension du contenu des fichiers . . . 3
2.1.2 Nettoyage et préparation des données . . . 3
2.2 Traitement des valeurs manquantes . . . 4
2.3 Fusion des sources . . . 4

3 Modélisation et Visualisation **5**
3.1 PMB(PhpMyBibli) . . . 5
3.1.1 C'est quoi un PMB et Pourquoi? . . . 5
3.1.2 Installation de PMB . . . 6
3.1.3 Réindexation dans PMB . . . 9
3.1.4 Exploration des données dans PMB . . . 11
3.2 Visualisations des données . . . 12
3.2.1 Power BI . . . 12

4 Conclusion **14**
4.1 Résumé . . . 14
4.2 Perspectives . . . 14

Chapter 1

Introduction

Les systèmes d'intelligence d'affaires (BI) combinent des données opérationnelles et historiques avec des outils analytiques pour fournir des informations précieuses et compétitives aux planificateurs et décideurs d'entreprise.
L'objectif de l'intelligence d'affaires est d'améliorer la rapidité et la qualité des informations, permettant ainsi aux gestionnaires de mieux comprendre la position de leur entreprise par rapport à leurs concurrents. Les applications et technologies de BI aident les entreprises à analyser les tendances changeantes en matière de part de marché, les évolutions du comportement et des habitudes de dépenses des clients, leurs préférences, les capacités de l'entreprise et les conditions du marché. L'intelligence d'affaires peut aider les analystes et les gestionnaires à déterminer quels ajustements sont les plus susceptibles de répondre aux tendances changeantes. L'émergence de l'entrepôt de données en tant que référentiel, les avancées dans le nettoyage des données, l'amélioration des capacités des matériels et logiciels, ainsi que l'apparition de l'architecture web, ont tous contribué à créer un environnement d'intelligence d'affaires plus riche qu'auparavant. Dans cet article, une tentative a été faite pour présenter un cadre pour la construction d'un système de BI.

1.1 Contexte

Dans le cadre de la modernisation et de l'optimisation de la gestion d'une bibliothèque, un projet a été initié pour nettoyer, organiser et analyser les données relatives aux ressources documentaires (livres, revues, médias, etc.), aux utilisateurs (emprunteurs) et aux transactions (prêts, retours). Les données ont été nettoyées pour éliminer les doublons, corriger les erreurs (par exemple, fautes de frappe dans les titres ou noms d'auteurs) et standardiser les formats (par exemple, dates ou catégories). Ces données propres ont ensuite été intégrées dans un Progiciel de Management de Bibliothèque (PMB) pour permettre une analyse approfondie et une gestion plus efficace.

1.2 Objectifs

L'objectif principal de ce projet est d'effectuer un processus de nettoyage, de transformation et d'intégration de données issues de deux fichiers hétérogènes (au format .csv et .xls) dans le système de gestion de bibliothèque PMB (PhpMyBibli).
Cette démarche vise à harmoniser les structures de données, corriger les incohérences, supprimer les doublons, et garantir la qualité et la fiabilité des informations intégrées dans la base documentaire. L'intégration dans PMB permettra ensuite une meilleure gestion, recherche et exploitation des ressources bibliographiques, tout en assurant leur pérennité dans un environnement professionnel normalisé.

Chapter 2

Nettoyage et Préparation des Données

2.1 Analyse des fichiers CSV et XLS

2.1.1 Identification et compréhension du contenu des fichiers

Dans le cadre de ce projet, deux fichiers de données ont été mis à disposition : un fichier CSV nommé buf.csv et un fichier Excel nommé bua.xls. Ces fichiers contiennent des métadonnées bibliographiques issues d'une base documentaire, et serviront de sources d'information pour alimenter un système de médiation documentaire, tel que PMB .
Fichier `buf.csv` Le fichier buf.csv est un fichier texte délimité, contenant des informations organisées sous forme de tableau. Il contient les colonnes suivantes : `Cote Titre Auteur Lieu Edition Annee Nb pages Matiere Inventaire`

2.1.2 Nettoyage et préparation des données

Avant toute exploitation des fichiers de données dans le cadre du système de médiation documentaire, une phase de nettoyage et de préparation est indispensable. Cette étape vise à corriger les incohérences, uniformiser les formats, et garantir la qualité des informations extraites. Les fichiers `buf.csv` et `bua.xls`, bien qu'ils contiennent des métadonnées bibliographiques précieuses, présentent certaines irrégularités telles que des valeurs manquantes, des doublons, ou des formats hétérogènes. Le nettoyage des données a donc consisté en plusieurs opérations essentielles telles que la vérification de l'encodage, la conversion de formats, l'harmonisation des champs textuels, et la suppression des enregistrements non exploitables. Ces traitements permettent d'assurer une intégration fiable des données dans une base documentaire normalisée.
La figure suivante illustre un exemple de doublon présent dans le fichier `bua.xls`, ce qui met en évidence la nécessité de vérifier l'unicité des enregistrements pour assurer la qualité et la cohérence des données.

7073	3/01	السينما المؤجلة	سويد, محمد	بيروت	مؤسسة الأبحاث ا عربية	1986	200	سينما في لبنان	19898
7074	3/01 مكرر	السينما المؤجلة	سويد, محمد	بيروت	مؤسسة الأبحاث ا عربية	1986	200	السينما في لبنان	23206

Figure 2.1: Exemple de ligne avec un doublon dans le fichier `bua.xls`.

La figure suivante illustre un exemple de doublon présent dans le fichier `buf.`

15182	159.9.052/57;L'enfant et la ville (table ronde);DACHMI abdeslam (coord);Rabat;Fac. des lettres;1999;144;Psychosociologie;29203
15183	159.9.052/57;L'enfant et la ville (table ronde);DACHMI abdeslam (coord);Rabat;Fac. des lettres;1999;144;Psychosociologie;29203

Figure 2.2: Exemple de ligne avec un doublon dans le fichier `buf.csv`.

2.2 Traitement des valeurs manquantes

L'un des aspects fondamentaux du nettoyage des données consiste à identifier et gérer les valeurs manquantes. Dans les fichiers `buf.csv` et `bua.xls`, certaines lignes présentent des champs vides, en particulier dans les colonnes critiques telles que `titre`, `auteur`, `éditeur` ou `année`. Ces absences peuvent nuire à la qualité des recherches bibliographiques et à l'indexation dans un système de gestion documentaire. Pour y remédier, une première étape a consisté à détecter systématiquement les cellules vides. Ensuite, selon l'importance de l'information manquante, différentes stratégies ont été adoptées : suppression des lignes incomplètes si elles étaient inutilisables, ou, dans certains cas, tentative de reconstitution manuelle à partir de sources externes (catalogues en ligne, ISBN). Ce traitement permet de garantir la cohérence et la fiabilité des données intégrées dans le système cible.
La figure suivante présente un exemple concret d'une ligne extraite du fichier bua.xls , dans laquelle le champ `Nb pages` est manquant, illustrant ainsi la nécessité du traitement des valeurs incomplètes.

Cote	Titre	Auteur	Lieu	Edition	Annee	Nb pages	Matiere	Inventaire
"011/07	فهرس المخطوطات العربية الترکية	(إعداد) فهيم علي ناصتاك	لندن - سر انفو	مكتبة العارف مكتبة	1998			27943

Figure 2.3: Exemple de ligne avec un champ vide dans le fichier `bua.xls`.

La figure suivante présente un exemple concret d'une ligne extraite du fichier `buf.csv`, dans laquelle le champ `Lieu` est manquant. Cette absence de valeur illustre clairement la nécessité d'un traitement rigoureux des données incomplètes afin de garantir la qualité de l'information bibliographique.

```
001_091_/01;La conquête du savoir = exploiring the earth and the cosmos;ASIMOV Isaac;;Marabout;1982;436;Science et connaissance;13105
```

Figure 2.4: Exemple de ligne avec un champ vide dans le fichier `buf.csv`.

2.3 Fusion des sources

La fusion de sources constitue une étape essentielle dans le processus d'intégration des données bibliographiques issues de plusieurs fichiers hétérogènes, tels que `bua.xls` et `buf.csv`. Cette opération vise à regrouper les informations disponibles dans un fichier unique et cohérent, facilitant ainsi leur exploitation et leur analyse. Avant la fusion proprement dite, il est impératif d'identifier et de traiter les problèmes de qualité des données, notamment la présence de doublons et de valeurs manquantes, comme illustré précédemment. Une harmonisation des structures de données a également été nécessaire afin d'uniformiser les noms de colonnes, les formats de dates et les types de champs. Une fois ces étapes préliminaires accomplies, les fichiers ont été fusionnés en se basant sur des champs communs tels que le titre ou le numéro d'inventaire, permettant ainsi de consolider les informations tout en évitant les redondances[2].

Chapter 3

Modélisation et Visualisation

3.1 PMB(PhpMyBibli)

3.1.1 C'est quoi un PMB et Pourquoi?

PMB (PhpMyBibli) est un système intégré de gestion de bibliothèques (SIGB) entièrement open source. Le projet a été lancé en octobre 2002 par François Lemarchand, qui était le directeur de la bibliothèque publique des Agneaux et qui est maintenant maintenu par PMB Services, une entreprise française [3]. Avec les technologies PHP, PMB fonctionne sur un serveur HTTP tel qu'Apache, une base de données MySQL et nécessite un serveur web. En tant qu'application web, elle fonctionne sur un serveur web et bénéficie donc de l'élasticité caractéristique des applications Internet [4].

Figure 3.1: PMB Logo

Dans le cadre de ce projet, nous avons utilisé le logiciel PMB (PhpMyBibli) comme système de gestion de base de données. Ce SIGB open source développé en PHP, reposant sur une base de données MySQL intégrée via XAMPP, a permis de structurer les données métiers sous forme de notices exploitables, tout en offrant une interface claire pour leur gestion.
L'accès à la base PMB a ensuite été réalisé à l'aide de scripts PHP via des connexions MySQL, dans le but d'extraire les données pertinentes et de les transformer pour une exploitation par des algorithmes de fouille de données. L'utilisation de PMB a ainsi facilité la structuration initiale des données, tout en assurant leur accessibilité pour les analyses en Business Intelligence.
Les article [5] et [6] ont présenté une étude comparative de plusieurs systèmes intégrés de gestion de bibliothèque, notamment Koha, Evergreen, NewGenLib, OpenBiblio et PMB. Selon différents critères, leurs résultats montrent que PMB se distingue comme la solution la plus complète et performante.

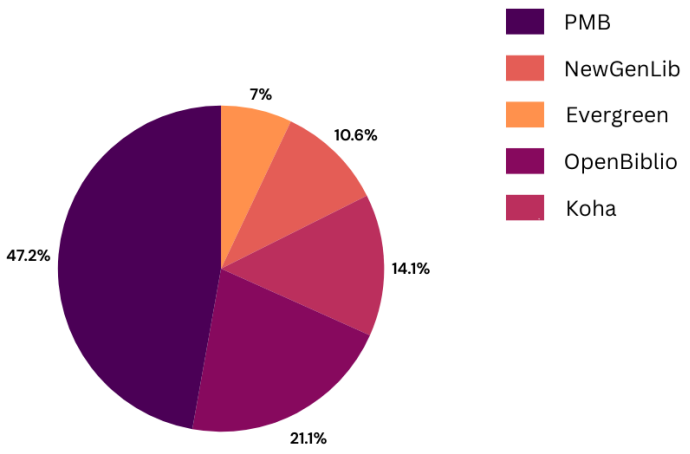

Figure 3.2: Résultat de l'évaluation des caractéristiques

3.1.2 Installation de PMB

Avant de procéder à l'installation de PMB, il est essentiel d'installer XAMPP sur l'appareil. XAMPP offre un environnement local intégrant Apache, MySQL, PHP et phpMyAdmin, qui sont essentiels pour le fonctionnement optimal de PMB. Il a la capacité d'accueillir l'application, de faire fonctionner les scripts PHP et de gérer la base de données MySQL.

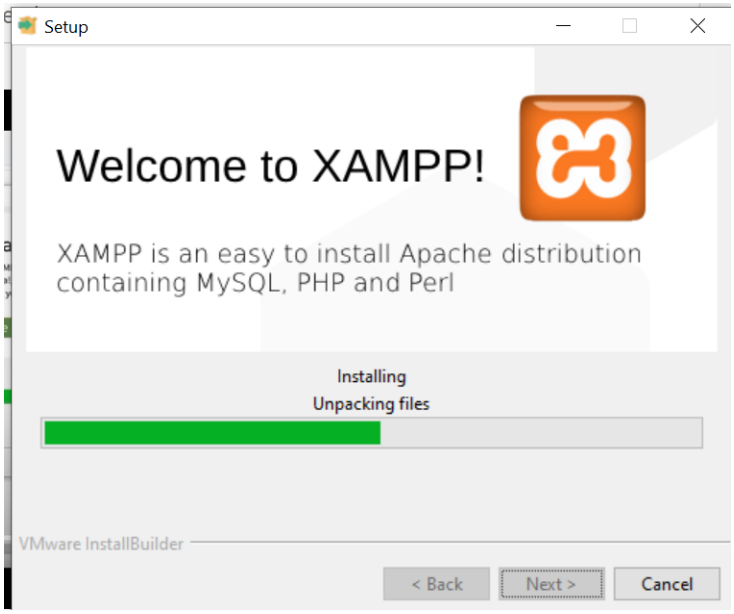

Figure 3.3: L'installation du XAMP

Une fois XAMPP installé, il est nécessaire d'activer les modules Apache et MySQL via le tableau de bord. Ces deux prestations sont indispensables : Apache facilite l'exécution de l'application web PMB en local, tandis que MySQL assure la gestion de la base de données employée par le système. Après l'activation de ces modules, l'environnement est configuré pour procéder à l'installation de PMB.

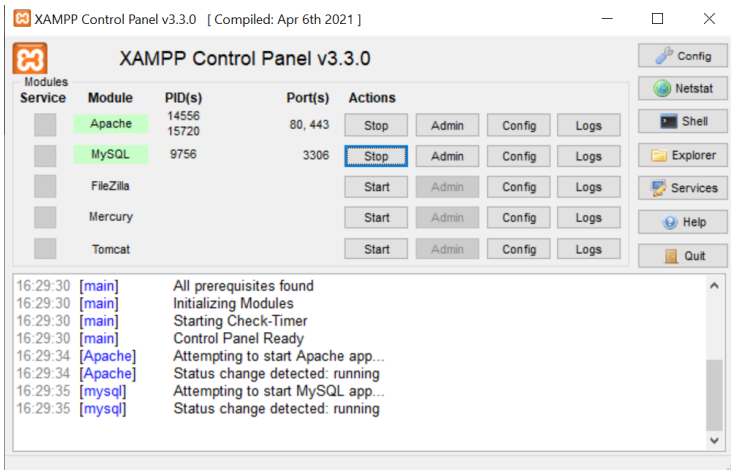

Figure 3.4: Lancement d'Apache et MySql

Une fois que vous avez décompressé l'archive ZIP qui contient le dossier PMB dans le répertoire htdocs de XAMPP, il vous suffit d'ouvrir un navigateur internet et de vous rendre à l'adresse `http://localhost/pmb` pour démarrer la procédure d'installation.

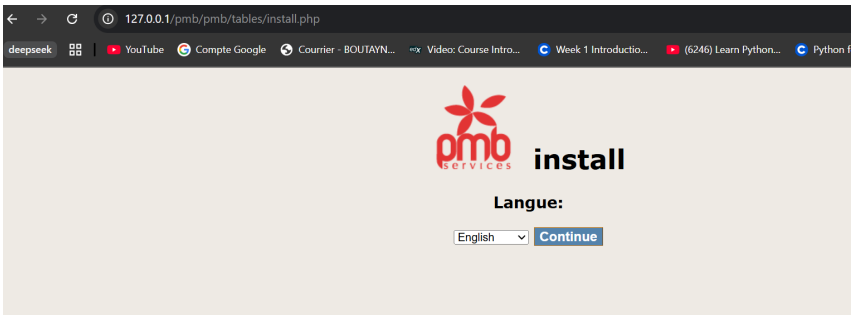

Figure 3.5: Début d'instalation

Une fois la langue sélectionnée et le bouton Installer cliqué, une liste des prérequis indispensables pour l'installation de PMB apparaît.
Cette phase consiste à s'assurer que tous les éléments nécessaires (tels que PHP, MySQL, les permissions d'écriture, etc.) sont bien disponibles et correctement paramétrés avant de continuer le processus d'installation.

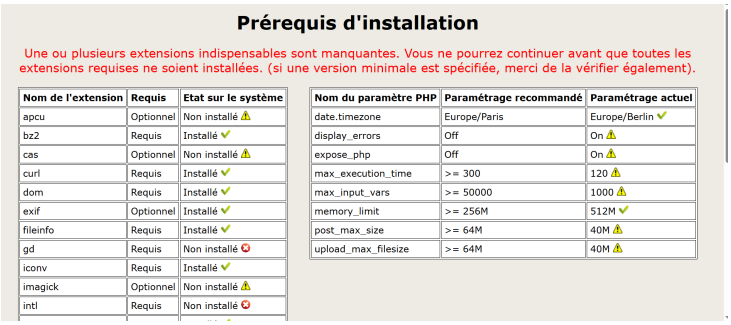

Figure 3.6: Les prérequis d'installation

Après cela, il est nécessaire d'ouvrir phpMyAdmin pour créer une base de données appelée pmb. Le système se servira de cette base pour conserver toutes les informations relatives aux utilisateurs, aux données bibliographiques et aux paramètres de configuration. Il suffit d'accéder à l'URL `http://localhost/phpmyadmin`, de sélectionner Nouvelle base , d'indiquer pmb comme nom et de confirmer la création.

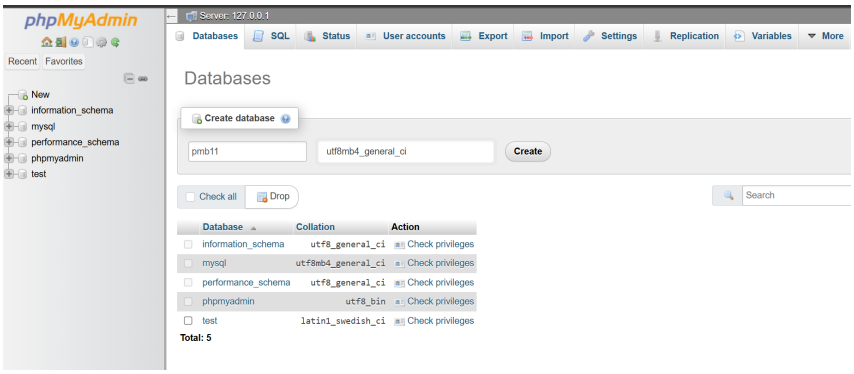

Figure 3.7: Création de la base de donné

Enuite l'assistant de configuration, des précisions sont demandées pour établir la connexion à la base de données MySQL.

Figure 3.8: Gestion du service MySQL

Après avoir réussi à se connecter à MySQL, il est impératif de configurer la base de données pmb. Cette phase permet à PMB de construire automatiquement la structure de la base de données, en créant toutes les tables, index et relations indispensables au fonctionnement optimal du système. L'utilisateur est donc tenu de confirmer ces configurations par le biais de l'assistant d'installation, qui prend en charge la mise en place intégrale de la base.
L'utilisateur doit :

- Valider la création de la structure de la base de données
- Insérer les données minimales, nécessaires au fonctionnement de base
- Choisir d'inclure les jeux de données de test et les données essentielles pour un démarrage rapide, ce qui est recommandé pour les nouveaux utilisateurs.

Ensuite, il convient de faire des choix obligatoires concernant :

- **Le thésaurus:** plusieurs options sont proposées, comme UNESCO, AGNEAUX ou ENVIRONMENT. Dans ce cas, l'option AGNEAUX est sélectionnée.
- **L'indexation interne:** différents styles sont disponibles, tels que Chambery, Dewey ou 100 cases. Ici, l'option Dewey Style est choisie, correspondant au système décimal universellement reconnu pour classer les documents.

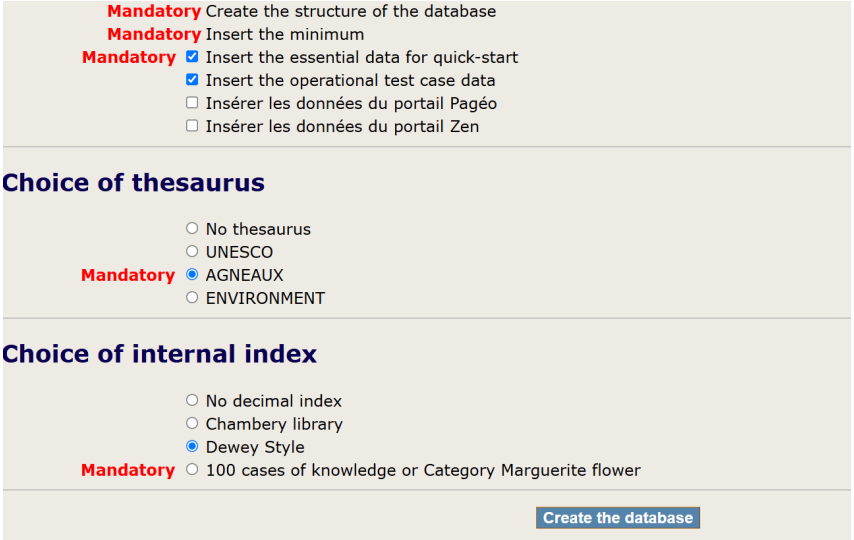

Figure 3.9: Interface de configuration initiale de la base de données PMB

Finalement, une fois que vous avez configuré les options requises, il vous suffit de presser le bouton Create the database . Le système se charge ensuite de l'installation intégrale de la base de données PMB. Un rapport d'installation apparaît à l'écran, décrivant la création des tables, l'ajout des données de base et notifiant tout message d'erreur ou de validation potentiel. Cette phase indique la conclusion de la mise en place technique de PMB, ce qui permet par la suite d'accéder à l'interface web dédiée à la gestion documentaire.

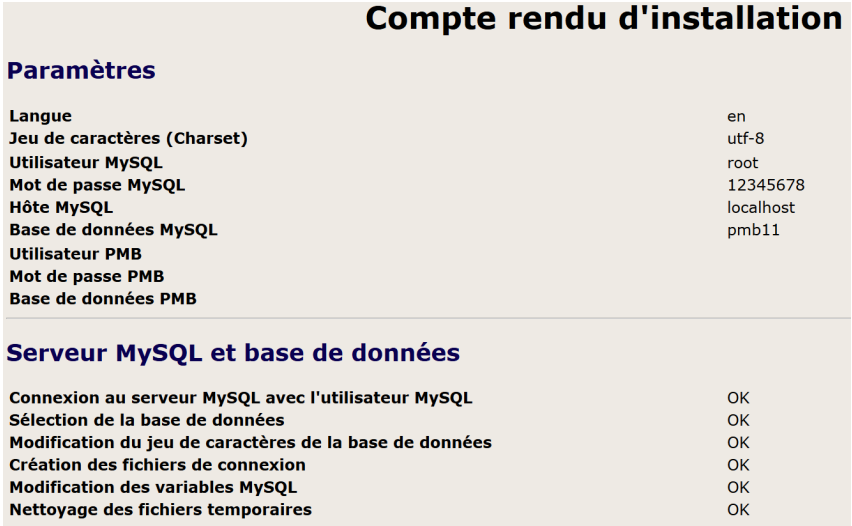

Figure 3.10: Résumé de l'installation de la base de données PMB

3.1.3 Réindexation dans PMB

La réindexation constitue une phase technique essentielle au fonctionnement de PMB. Elle offre la possibilité de créer ou de recréer les index de recherche employés par le moteur interne. Cette opération devient nécessaire après des modifications importantes de la base de données (ajout ou suppression de notices, mise à jour massive des champs, etc.), ou à la suite d'une importation de données.
Elle s'initie depuis l'interface d'administration, sous la rubrique Outils ¿ Réindexation, et peut concerner divers genres de données : fiches bibliographiques, autorités, exemplaires, etc. Après l'achèvement de la réindexation, les recherches des utilisateurs gagnent en pertinence, puisqu'elles se basent sur des index actualisés.
Ici, les options de réindexation globale et des champs de recherche sont sélectionnées.

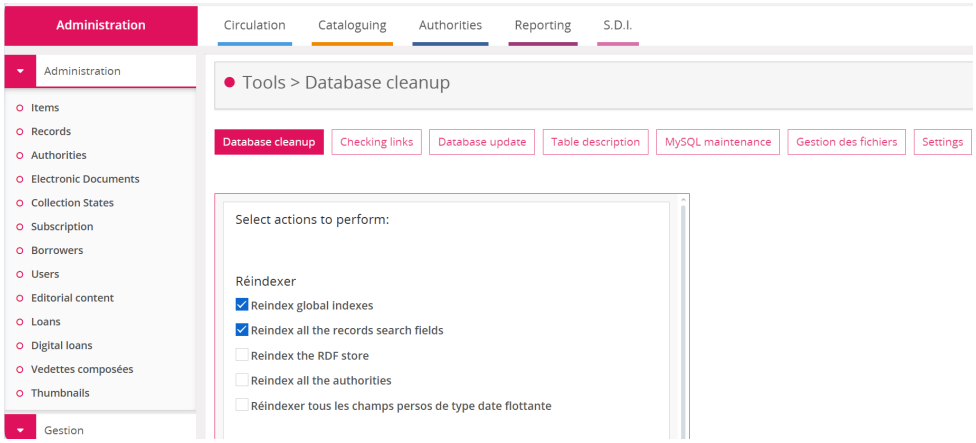

Figure 3.11: Réindexation dans PMB

Lors de l'initiation de la réindexation via l'outil Database cleanup dans PMB, le système passe par une série de phases pour actualiser les index de la base de données. La réindexation des auteurs et des éditeurs est particulièrement cruciale parmi ces éléments.
Ce processus vise à réajuster et à réorganiser les index en rapport avec les informations des auteurs et des éditeurs, garantissant ainsi une parfaite consistance des données référencées. La bonne exécution de cette procédure assure que les recherches dans la base de données soient exactes et rapides, facilitant l'accès aux références bibliographiques pertinentes.

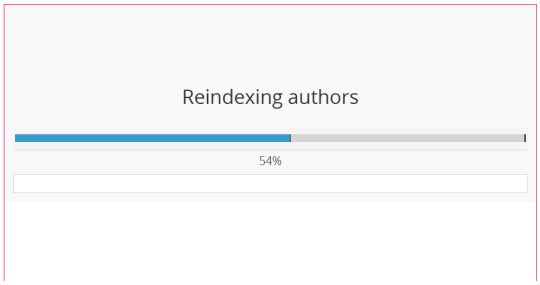

Figure 3.12: Réindexation des auteures

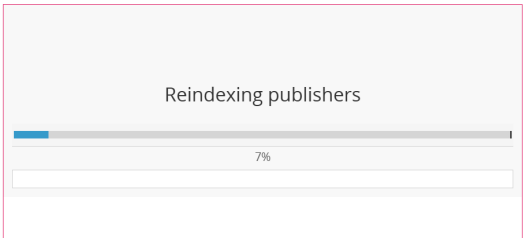

Figure 3.13: Réindexation des éditeurs

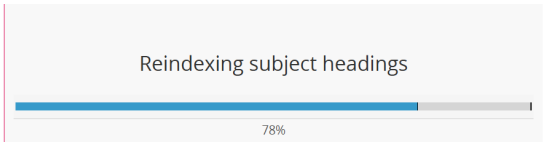

Figure 3.14: Réindexation des matières

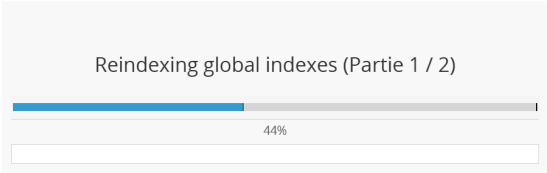

Figure 3.15: Réindexation des index généraux

Finalement, nous observons que la procédure de réindexation est maintenant achevée. On peut désormais de façon efficace explorer et interroger les diverses entités (auteurs, éditeurs, vedettes matières, etc.) dans PMB. Cette phase est indispensable pour assurer la consistance des données et garantir la pertinence des résultats lors de l'examen documentaire.

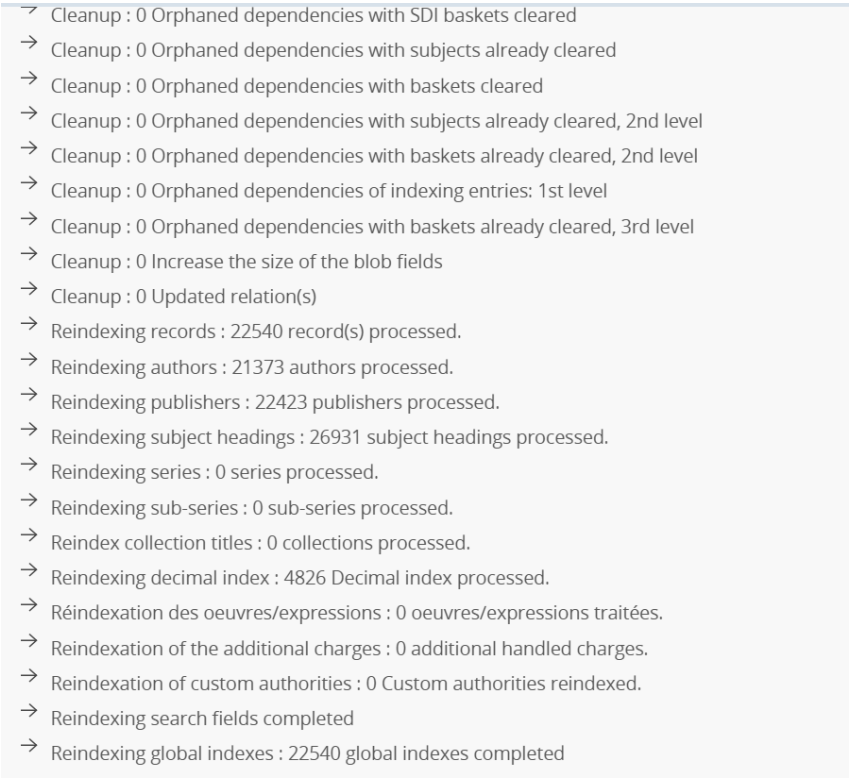

Figure 3.16: Fin du processus de réindexation

3.1.4 Exploration des données dans PMB

Une fois la réindexation achevée,l'utilisateur a accès à l'ensemble des fonctionnalités requises pour naviguer dans les diverses entités bibliographiques présentes dans le système PMB. Cela englobe en particulier les auteurs, les éditeurs, les sujets principaux, les titres, ainsi que les fiches détaillées liées aux documents. Avec les fonctionnalités de recherche avancée, de navigation par sujets et d'affichage approfondi, on peut désormais interroger spécifiquement la base de données et accéder directement aux informations appropriées. Cette faculté d'exploration rend considérablement le travail de recherche de documents, d'analyse bibliographique et de gestion des collections plus facile.
Les figures présentées ci-dessous illustrent concrètement cette phase d'exploration des données au sein de PMB. Elles montrent l'accessibilité et la cohérence des informations récemment réindexées, confirmant ainsi le bon déroulement du processus de mise à jour et la fiabilité du système dans son ensemble.

Figure 3.17: Recherche par titre

Figure 3.18: Recherche par autheur

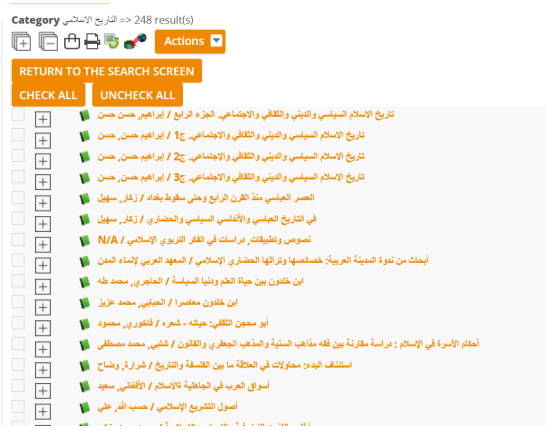

Figure 3.19: Recherche par matière

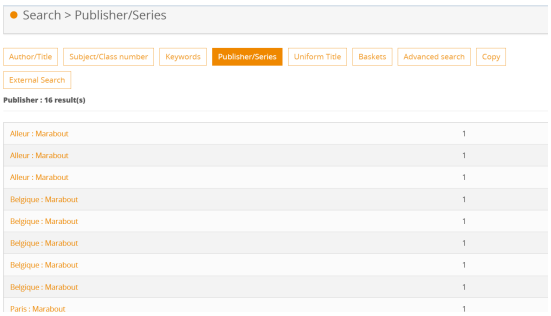

Figure 3.20: Recherche par editeur

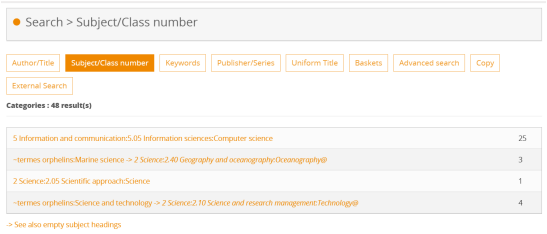

Figure 3.21: Recherche par cote

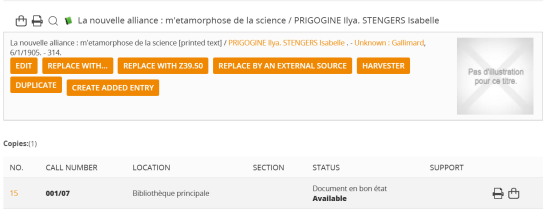

Figure 3.22: Recherche par inventaire

3.2 Visualisations des données

La visualisation d'un ensemble de données est un processus qui permet de faire comprendre la signification des données par le biais de contexte visuel et fait partie de l'analyse des données où elle est exécutée après la correction des données. De nos jours, la visualisation est de plus en plus utile pour la veille économique et l'analyse dans tous les domaines. Il existe différentes techniques pour visualiser les ensembles de données, qui peuvent être de nature dynamique ou interactive, et les ensembles de données peuvent être visualisés dans différents types d'aperçus visuels[7].

3.2.1 Power BI

Power BI est un outil de Business Intelligence développé par Microsoft, qui permet de créer des tableaux de bord et des rapports interactifs à partir de données issues de sources diverses. Dans le cadre de ce projet, Power BI a été utilisé pour exploiter les données extraites du système PMB via MySQL et traitées avec PHP.

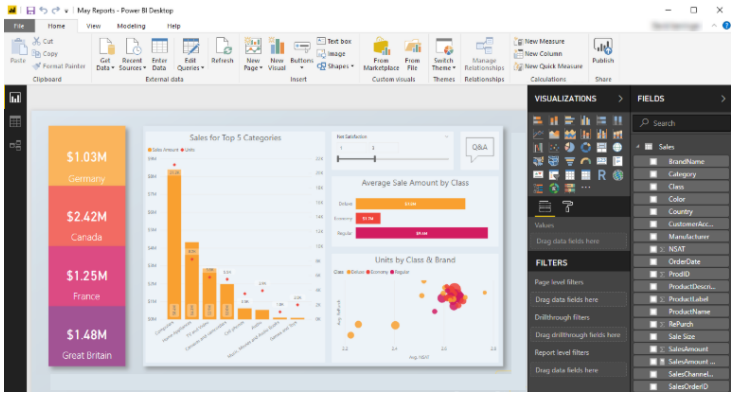

Figure 3.23: Linterface de Power BI

Les données ont été importées dans Power BI, où elles ont été préparées et transformées grâce à Power Query afin d'assurer leur cohérence et leur qualité. Différents types de visualisations ont été créés, incluant des graphiques en barres, des diagrammes sectoriels, des tableaux croisés dynamiques et des indicateurs clés de performance (KPI).
Ces visualisations ont permis d'analyser efficacement les prêts de documents, la fréquentation des usagers et la gestion des collections. Elles offrent une interface intuitive qui facilite la compréhension des données pour les gestionnaires de la bibliothèque, contribuant ainsi à une prise de décision plus rapide et mieux informée.
L'utilisation de Power BI dans ce projet illustre l'importance des outils de visualisation dans la démarche de Business Intelligence, en transformant des données brutes en informations stratégiques facilement exploitables.

Chapter 4

Conclusion

4.1 Résumé

Le projet présenté dans ce rapport avait pour objectif de moderniser et d'optimiser la gestion d'une bibliothèque à travers le nettoyage, la transformation et l'intégration de données hétérogènes issues de deux fichiers (`buf.csv` et `bua.xls`) dans le système de gestion de bibliothèque PMB (PhpMyBibli). Les étapes clés ont inclus l'analyse et le nettoyage des données pour éliminer les doublons, corriger les erreurs et standardiser les formats, suivis de leur intégration dans une base de données normalisée. L'utilisation de PMB a permis de structurer les métadonnées bibliographiques sous forme de notices exploitables, tandis que l'outil Power BI a transformé ces données en visualisations interactives, telles que des graphiques en barres, des diagrammes sectoriels et des tableaux croisés dynamiques. Ces visualisations ont permis d'analyser les tendances des prêts, le comportement des usagers et l'état des collections, offrant ainsi des informations stratégiques pour une prise de décision éclairée. Ce projet a démontré l'importance des technologies de Business Intelligence (BI) dans la gestion documentaire, en améliorant la rapidité, la qualité et l'accessibilité des informations.

4.2 Perspectives

Pour optimiser le système de gestion documentaire, deux améliorations clés sont envisagées :

1. **Automatisation du nettoyage des données avec le machine learning :** Le nettoyage manuel des données (`buf.csv` et `bua.xls`), incluant la correction des erreurs et le traitement des valeurs manquantes, est chronophage. L'utilisation d'algorithmes de machine learning, tels que des modèles d'imputation, permettrait d'automatiser la détection des anomalies (par exemple, fautes de frappe) et la reconstruction des données manquantes (par exemple, années de publication). Cette approche accélérerait l'intégration des données dans PMB, réduirait les erreurs et libérerait du temps pour les analyses stratégiques.

2. **Intégration de données supplémentaires pour des analyses enrichies :** Le système actuel se limite aux données sur les prêts, les usagers et les collections. Intégrer des informations additionnelles, comme les réservations ou les retours tardifs, offrirait une vision plus complète des besoins des usagers. Par exemple, les données de réservations pourraient révéler des documents très demandés, tandis que les retours tardifs signaleraient des ajustements nécessaires dans les politiques de prêt. Ces données, visualisées via Power BI, permettraient des décisions plus précises pour optimiser la gestion des ressources.

Ces perspectives renforcent l'efficacité et la pertinence du système, garantissant une gestion documentaire adaptée aux besoins actuels et futurs de la bibliothèque.

Bibliography

[1] *BUSINESS INTELLIGENCE: CONCEPTS, COMPONENTS, TECHNIQUES AND BENEFITS*

[2] *CSV on the Web Working Group (W3C)*2015.

[3] *K. T. Anuradha, Enhancing Features of Library Automation Package by Integrating with Discovery Tool: A Case Study, s.l., s.n.,*

[4] *Chandran, V., et al. Role of Open Source System with Special Reference to Selected Integrated Library System Softwares on Libraries in Digital Era. Communication présentée à une conférence, août 2014.*

[5] *Oukrich, J., Bouikhalene, B., & Askour, N. (n.d.). A comparative study of the open source digital library software. MPA, Sultan Moulay Slimane University, Morocco.*

[6] *Anantharaj, S., Velmurugan, C., & Kavitha, G. (2014, August). Role of open source system with special reference to selected integrated library system softwares on libraries in digital era. Chennai, India.*

[7] *Bhargava, M. G., Kiran, K. T. P. S., Rao, D. R. (n.d.). Analysis and design of visualization of educational institution database using Power BI tool. Koneru Lakshmaiah Educational Foundation.*